

Prof. R. Rojas

Mustererkennung, WS17/18

Übungsblatt 9

Boyan Hristov, Nedeltscho Petrov

18. Dezember 2017

Link zum Git Repository: <https://github.com/BoyanH/FU-MachineLearning-17-18/tree/master/Solutions/Homework9>

Neural Networks

Wir haben zwei Implementierungen - eine mit streng nur 1 hidden Layer und eine, die als Argument ein Tupel, dass die Anzahl von Neuronen pro Layer beschreibt und damit auch die Anzahl von layers. Die komplexere Implementierung ist aber deutlich weniger lesbar und viel zu schwierig einzustellen. Deswegen werden uns hier auf die Beschreibung unserer simpleren Implementierung konzentrieren. Beide Implementierungen sind am Ende des Blattes zu sehen.


Evaluation

Die Methode ist, wie man später anhand der booleschen Funktionen sieht, viel mächtiger, aber auch viel schwieriger einzustellen. Wir haben eine Fehlerrate von knapp über 11% dass das eher an der Lernrate und Anzahl von Neuronen / Schichten im Netz hängt. Die Methode ist auch sehr aufwändig im Sinne von Rechnerressourcen, wie aber im Tutorial beschrieben, könnte diese effizient in Hardware implementiert werden. Wenn wir aber uns entschieden sollen für diesen Datensatz (Ziffererkennung) wurden wir eher eine lineare Methode nehmen, die viel schneller ist und leichter zu interpretieren. Wir haben aber immer noch Hoffnung, dass wir bessere neuronale Netze implementieren werden ‘

Wie wir auf der offizieller Seite des Datensatz gesehen haben, benutzen die Leute echt viele hidden Layers um die Daten gut zu klassifizieren. Leider sind beide unsere Implementierung und Rechnern nicht so perfekt für solche Ansätze.

Fehler über die Iterationen


1 Hidden Layer mit 15 Neuronen



Output:

Score: 0.88458781362

1 Hidden Layer mit 20 Neuronen




Output:

Score: 0.8863799283154122

Score train: 0.9512907191149355

1 Hidden Layer mit 25 Neuronen



Output:

Score train: 0.8678549477566072

Score: 0.8182795698924731

2 Hidden Layers mit 20 und 15 Neuronen, circa 7 Batches (max. 1000 Beispiele pro Batch)

Wir wurden gerne noch mehr mit mehreren Schichten spielen, das war aber viel zu rechenaufwändig...

Wie man aber hier sieht, haben wir bei den Testdatensatz besseres Score als bei den Trainingsdataset, was ein sehr gutes Zeichen in Richtung "nicht auswendig lernen". Yey M

Output



```
1 Score train: 0.7744314689612785
2 Score: 0.7548387096774194
4 \includegraphics[height=8cm]{./2_hidden_layers_20_15_with_7_batches.png}
```


1 Hidden Layer, 20 Neuronen, großen Datensatz

Boolesche Funktionen

Output

```
1 Score and: 1.0
2 Score or: 1.0
3 Score xor: 1.0
```





Erklärung des Codes

Diesmal gibt es extrem wenig zu erklären, da das meiste Code von der Vorlesung / Tutorial 1 zu 1 genommen wurde und die Matrizenmultiplikationen in python geschrieben wurden. Nur eine Transponierung hat gefehlt in den Formeln, dazu kommen wir noch.

Fit Methode

Interessant hier wäre vielleicht, dass wir den Datensatz in Batches mit je 5000 Beispiele unterteilen, sonst können wir von den großen Datensatz gar nicht lernen. Adaptive Lernrate hat uns in dem Beispiel nicht geholfen, wahrscheinlich war die Fehler kleiner wird und damit auch ihre Ableitung, wir korrigieren mit der Zeit immer weniger.

```

1  def fit(self, X, y):
2      self.history = []
3      self.unique_labels = np.unique(y)
4      X_ = self.data_normalizer.fit_transform(X)
5      y_ = self.transform_y(y)
6      self.W1 = np.vstack((
7          np.random.randn(len(X_[0]), self.size_hidden),
8          np.ones(self.size_hidden)))
9      self.W2 = np.vstack((
10         np.random.randn(self.size_hidden, self.size_output),
11         np.ones(self.size_output)))
12
13     batch_size = 5000
14     for batch_start in range(0, len(X_), batch_size):
15         Xb = X_[batch_start:batch_start + batch_size]
16         yb = y_[batch_start:batch_start + batch_size]
17         for i in range(self.max_iterations):
18             o_, o1, o2, o2_ = self.feed_forward(Xb)
19             W2_ = self.W2[:-1]
20             d1 = NN.sigmoid_derived(o1) # not diagonal matrix as in lecture, because
sigmoid_derived(o1) is a vector
21             d2 = NN.sigmoid_derived(o2)
22             e = o2 - yb

```

```

23         delta2 = d2 * e
24         # transposing of the weights matrix missing in formula in lecture/tutorial
of professor
25         delta1 = d1 * (delta2.dot(W2_.T))
26         deltaW2 = (-self.learning_rate * (delta2.T.dot(o1_))).T
27         deltaW1 = (-self.learning_rate * delta1.T.dot(o_)).T
28         self.W1 += deltaW1
29         self.W2 += deltaW2
31
32         # self.learning_rate = self.learning_rate * 1 / (1 + 0.0001 * i)
self.history.append(self.score(X, y))

```

Labels zu gewünschten Output

Interessant ist vielleicht, dass wir von den Netz 10 Outputs haben für je Ziffer und diese müssen wir mit den Labels vergleichen können. Dafür haben wir die folgende Methoden benutzt und damit auch die folgende Predict Methode. Dabei nehmen wir das Output der letzten Schicht in dem Netz und wählen den Neuron mit der größten Wert. Danach sollen wir dass wieder zu ein Label mappen, deswegen haben wir alle Mögliche Labels gespeichert. In der transform_y mappen wir z.B. 4 zu

0, 0, 0, 1.0, 0, 0, 0, 0

```

1 def transform_y(self, y):
2     y_ = np.zeros((len(y), len(self.unique_labels)))
3     y_in_unique = np.vectorize(lambda x: list(self.unique_labels).index(x))(y)
4     y_[range(len(y)), y_in_unique] = 1
5     return y_
7
8 def predict(self, X):
9     X = self.data_normalizer.transform(X)
10    return self.predict_(X)
11
12 def predict_(self, X):
13     o2 = self.feed_forward(X)[3]
14     return self.unique_labels[o2.argmax(1)]

```

Sigmoid-Funktion und ihre Ableitung

```

1 @staticmethod
2     def sigmoid(x):
3         return 1 / (1 + np.exp(-x))
5
6 @staticmethod
7     def sigmoid_derived(x):
8         return x*(1-x)

```

Vollständiges Code boolean_functions_nn.py

```

1 import numpy as np
2 from NN import NN

```

```

5 X = np.array([
6     [0,0],
7     [0,1],
8     [1,0],
9     [1,1]
10 ])
11 y_and = np.array([a & b for a,b in X])
12 y_or = np.array([a | b for a,b in X])
13 y_xor = np.array([a ^ b for a,b in X])

14 # AND
15 nn = NN(max_iterations=3000, size_hidden=10, size_output=2, learning_rate=0.01)
16 nn.fit(X, y_and)
17 nn.plot_accuracies('./nn_and.png')
18 print('Score and: {}'.format(nn.score(X, y_and)))

21 # OR
22 nn = NN(max_iterations=3000, size_hidden=10, size_output=2, learning_rate=0.01)
23 nn.fit(X, y_or)
24 nn.plot_accuracies('./nn_or.png')
25 print('Score or: {}'.format(nn.score(X, y_or)))

27 # XOR
28 nn = NN(max_iterations=3000, size_hidden=10, size_output=2, learning_rate=0.01)
29 nn.fit(X, y_and)
30 nn.plot_accuracies('./nn_xor.png')
31 print('Score xor: {}'.format(nn.score(X, y_and)))

```

Vollständiges Code digits_small_nn.py digits_big_nn.py analog

```

1 from Parser import get_data_set
2 from NN import NN

5 X_train, X_test, y_train, y_test = get_data_set('digits.data')
6 nn = NN()
7 nn.fit(X_train, y_train)
8 nn.plot_accuracies()
9 print('Score train: {}'.format(nn.score(X_train, y_train)))
10 print('Score: {}'.format(nn.score(X_test, y_test)))

```

Vollständiges Code NN.py

```

1 from Classifier import Classifier
2 from DataNormalizer import DataNormalizer
3 import numpy as np
4 from matplotlib import pyplot as plt

7 class NN(Classifier):
8     def __init__(self, max_iterations=3000, learning_rate=0.0020, size_hidden=20,
9         size_output=10):
10         self.data_normalizer = DataNormalizer()
11         self.size_hidden = size_hidden
12         self.size_output = size_output
13         self.max_iterations = max_iterations
14         self.learning_rate = learning_rate
15         self.W1 = None

```

```

15     self.W2 = None
16     self.unique_labels = None

18     def fit(self, X, y):
19         self.history = []
20         self.unique_labels = np.unique(y)
21         X_ = self.data_normalizer.fit_transform(X)
22         y_ = self.transform_y(y)
23         self.W1 = np.vstack((
24             np.random.randn(len(X_[0]), self.size_hidden),
25             np.ones(self.size_hidden)))
26         self.W2 = np.vstack((
27             np.random.randn(self.size_hidden, self.size_output),
28             np.ones(self.size_output)))

30         batch_size = 5000
31         for batch_start in range(0, len(X_), batch_size):
32             Xb = X_[batch_start:batch_start + batch_size]
33             yb = y_[batch_start:batch_start + batch_size]
34             for i in range(self.max_iterations):
35                 o_, o1, o1_, o2, o2_ = self.feed_forward(Xb)
36                 W2_ = self.W2[:-1]
37                 d1 = NN.sigmoid_derived(o1) # not diagonal matrix as in lecture, because
sigmoid_derived(o1) is a vector
38                 d2 = NN.sigmoid_derived(o2)
39                 e = o2 - yb
40                 delta2 = d2 * e
41                 # transposing of the weights matrix missing in formula in lecture/tutorial
of professor
42                 delta1 = d1 * (delta2.dot(W2_.T))
43                 deltaW2 = (-self.learning_rate * (delta2.T.dot(o1_))).T
44                 deltaW1 = (-self.learning_rate * delta1.T.dot(o_)).T
45                 self.W1 += deltaW1
46                 self.W2 += deltaW2

48                 # self.learning_rate = self.learning_rate * 1 / (1 + 0.0001 * i)
49                 self.history.append(self.score(X, y))

51     def feed_forward(self, X):
52         o_ = np.c_[X, np.ones(len(X))]
53         o1 = NN.sigmoid(o_.dot(self.W1))
54         o1_ = np.c_[o1, np.ones(len(o1))]
55         o2 = NN.sigmoid(o1_.dot(self.W2))
56         o2_ = np.c_[o2, np.ones(len(o2))]

58         return o_, o1, o1_, o2, o2_

60     @staticmethod
61     def sigmoid(x):
62         return 1 / (1 + np.exp(-x))

64     @staticmethod
65     def sigmoid_derived(x):
66         return x*(1-x)

68     def transform_y(self, y):
69         y_ = np.zeros((len(y), len(self.unique_labels)))
70         y_in_unique = np.vectorize(lambda x: list(self.unique_labels).index(x))(y)
71         y_[range(len(y)), y_in_unique] = 1
72         return y_

74     def predict(self, X):
75         X = self.data_normalizer.transform(X)
76         return self.predict_(X)

78     def predict_(self, X):
79         o2 = self.feed_forward(X)[3]
80         return self.unique_labels[o2.argmax(1)]

```



```

82     def plot_accuracies(self, file_name=None):
83         plt.figure(figsize=(12, 7))
84         plt.plot(self.history)
85         plt.xlabel("Iterations")
86         plt.ylabel("accuracy")
87
88         if file_name is None:
89             plt.show()
90         else:
91             plt.savefig(file_name)

```

Vollständiges Code NeuralNetwork.py

```

1  from Classifier import Classifier
2  from DataNormalizer import DataNormalizer
3  import numpy as np
4  from matplotlib import pyplot as plt
5  from Parser import get_data_set
6
7
8  class NeuralNetwork(Classifier):
9      def __init__(self, layers=None, max_iterations=3000, learning_rate=0.0025):
10         """
11
12         :param layers: tuple defining the amount of neurons to be used pro layers, thereby
13         defining the network
14         :param max_iterations:
15         :param learning_rate:
16         """
17         self.data_normalizer = DataNormalizer()
18         self.W_ext = None
19         self.max_iterations = max_iterations
20         self.learning_rate = learning_rate
21         self.layers = layers
22         self.history = []
23
24         if self.layers is None:
25             self.k_layers = 3
26         else:
27             self.k_layers = len(self.layers)
28
29     def transform_y(self, y):
30         y_ = np.zeros((len(y), len(self.unique_labels)))
31         y_in_unique = np.vectorize(lambda x: list(self.unique_labels).index(x))(y)
32         y_[range(len(y)), y_in_unique] = 1
33         return y_
34
35     def fit(self, X, y):
36         self.unique_labels = np.unique(y)
37         X_ = self.data_normalizer.fit_transform(X)
38         y_ = self.transform_y(y)
39
40         if self.layers is not None:
41             self.W_ext = np.array([np.random.randn(len(X_[0]) + 1, self.layers[i]) if i ==
42             0 else
43                                     np.random.randn(self.layers[i - 1] + 1, self.layers[i])
44                                     for i in self.layers])
45         else:
46             self.W_ext = np.array([np.random.randn(len(X_[0]) + 1, 20), np.random.randn(20
47             + 1, 15),
48                                     np.random.randn(15+1, 10)])
49
50         batch_size = 1000

```

```

48     for batch_start in range(0, len(X_), batch_size):
49         Xb = X_[batch_start:batch_start + batch_size + 1]
50         yb = y_[batch_start:batch_start + batch_size + 1]
51         for it in range(self.max_iterations):
52             O_s = self.get_O_s(Xb)
53             D_s = [(o * (1.0 - o)) for o in O_s[2::2]]
54             e = (O_s[-1] - yb)
55             der_e_s = self.get_der_e_s(D_s, e)
56             delta_W_ext = self.get_delta_W_ext(der_e_s, O_s[2::2])
57
58             for i, delta in enumerate(delta_W_ext):
59                 self.W_ext[i] += delta
60
61         self.history.append(self.score(X, y))
62
63     @staticmethod
64     def add_ones(X):
65         return np.c_[np.ones(len(X)), X]
66
67     @staticmethod
68     def sigmoid(x):
69         return 1 / (1 + np.exp(-x))
70
71     def get_O_s(self, X):
72         O_s = [X]
73         for i in range(self.k_layers):
74             O_i_minus_1 = np.c_[O_s[-1], np.ones(len(X))] # extend to get o(i-1)^
75             O_s.append(O_i_minus_1)
76             O_i = NeuralNetwork.sigmoid(O_i_minus_1.dot(self.W_ext[i]))
77             O_s.append(O_i)
78
79         return O_s
80
81     def get_der_e_s(self, D_s, e):
82         W = [w[1:] for w in self.W_ext]
83         der_e_l = e * D_s[-1]
84         der_e_s = [der_e_l]
85
86         for i in range(self.k_layers - 1):
87             der_e_i = D_s[-i - 2] * (der_e_s[0]).dot(W[-i - 1].T)
88             der_e_s = [der_e_i] + der_e_s
89
90         return der_e_s
91
92     def get_delta_W_ext(self, der_e_s, O_s):
93         delta_W_ext = []
94
95         for i in range(self.k_layers):
96             o_i_ext = np.c_[O_s[i], np.ones(len(O_s[i]))]
97             delta_W_i = der_e_s[i].T.dot(o_i_ext)
98             delta_W_ext.append(delta_W_i.T)
99
100         return np.array(delta_W_ext) * -self.learning_rate
101
102     def predict(self, X):
103         X = self.data_normalizer.transform(X)
104         return self.predict_(X)
105
106     def predict_(self, X):
107         O_s = self.get_O_s(X)
108         results = O_s[-1]
109         return self.unique_labels[results.argmax(1)]
110
111     def plot_accuracies(self, file_name=None):
112         plt.figure(figsize=(12, 7))
113         plt.plot(self.history)
114         plt.xlabel("Iterations")
115         plt.ylabel("accuracy")

```

```
117         if file_name is None:
118             plt.show()
119         else:
120             plt.savefig(file_name)

123 X_train, X_test, y_train, y_test = get_data_set('digits.data')
124 nn = NeuralNetwork()
125 nn.fit(X_train, y_train)
126 nn.plot accuracies('./2_hidden_layers_20_15_with_7_batches.png')
127 print('Score train: {}'.format(nn.score(X_train, y_train)))
128 print('Score: {}'.format(nn.score(X_test, y_test)))
```